

SVEUČILIŠTE U ZAGREBU
PRIRODOSLOVNO-MATEMATIČKI FAKULTET
MATEMATIČKI ODSJEK
2019./2020.

SEMINARSKI RAD

Prepoznavanje emocija iz teksta

Aida Omanović

Manuela Pleša

Petra Škrabo

Mentor: prof. dr. sc. Luka Grubišić

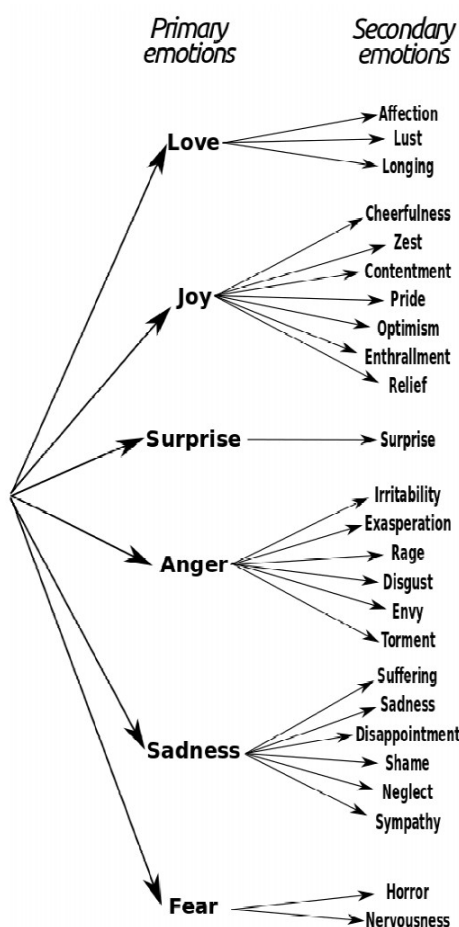
1. UVOD.....	2
2. ANALIZA RJEŠENJA.....	4
2.1 Opis pristupa problemu.....	4
2.2 Baza podataka.....	4
2.3 Analiza koda.....	7
3. PRIMJERI.....	8
4. ZAKLJUČAK.....	9
5. LITERATURA.....	10

1. UVOD

Interakcija između čovjeka i računala uglavnom se odvija preko tipkovnice, zaslona, govornih aplikacija i slično. Svi ti alati eksplicitno prevode poruke govornika, ali uglavnom zanemaruju njegov emocionalni status, filtrirajući taj dio informacija iako je on dostupan u procesu interakcije. Uređaj koji je svjestan emocija može reagirati na prikladniji način i osobnije komunicirati s vlasnikom.

Zbog svega toga smo se u našem projektu odlučili usredotočiti na otkrivanje emocija.

Taj problem nije nimalo jednostavan budući da su emocije poprilično subjektivne i teško je pronaći objektivnu i univerzalnu definiciju „emocije“. To nam potvrđuje i činjenica da su se kroz povijest pojavljivale različite klasifikacije emocija. Mi smo se odlučili za Ekmanovu (1972.) podjelu na 6 „osnovnih“ emocija za koje je utvrđeno da ih pronalazimo u facijalnoj ekspresiji svih kultura pa se samim time smatra da su one urođene.



Slika 1. Ekmanova klasifikacija emocija

Dakle, baziramo se na sljedeće emocije: *ljubav, radost, iznenađenost, ljutnju, tugu i strah*.

Umjetna emocionalna inteligencija temelji se na prepoznavanju i otkrivanju emocija. Moguće ju je realizirati na više različitih načina koji uključuju obradu teksta, slike ili zvuka. Mi smo se odlučili za prepoznavanje emocija iz teksta. Preciznije, procjenjivat ćemo zastupljenost svake od 6 osnovnih emocija u ulaznoj rečenici.

Tehnike otkrivanja emocija iz teksta mogu se podijeliti u tri kategorije: otkrivanje emocija na temelju ključne riječi, otkrivanje emocija na temelju učenja, hibridno otkrivanje koje objedinjuje obe.

Za rješenje danog problema odlučili smo koristiti povratne neuronske mreže (engl. *Long Short-Term Memory units, LSTM*) s mehanizmom pažnje, budući da imaju visoku točnost i takav pristup je dokazano među najboljim za rješavanje ovakvih tipova problema.

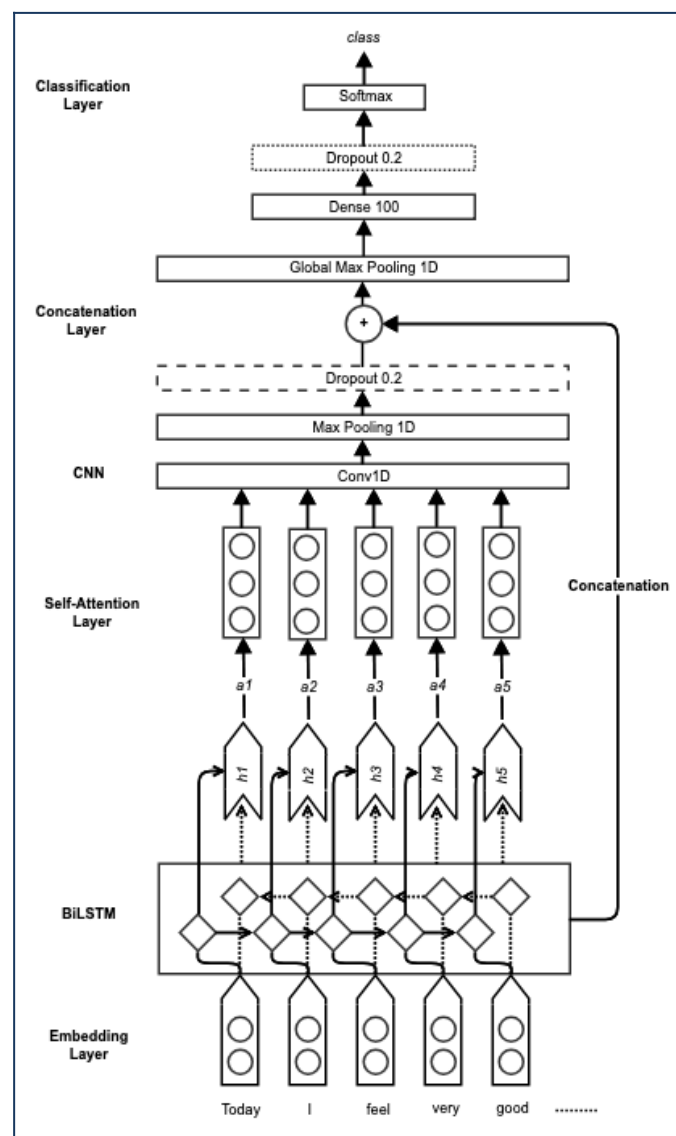
Kod smo pisali u programskom jeziku Python s naglaskom na njegovu biblioteku za duboko učenje Keras.

2. ANALIZA RJEŠENJA

2.1 Opis pristupa problemu

Prethodno navedeni pristup za rješavanje danog klasifikacijskog problema uzastopno obrađuje riječi zadane rečenice u ulaznom sloju. Kao posljednji izlaz dobivamo značenje rečenice, odnosno u našem slučaju postotak zastupljenosti svake od 6 glavnih emocija u njoj.

Na sljedećoj slici prikazan je model.



Slika 2. Model za prepoznavanje emocija

2.2 Slojevi modela

2.2.1. Ulazni sloj

Ovo je prvi sloj neuronske mreže. On uzima ulazne vrijednosti i prosljeđuje ih sljedećem sloju ne primjenjujući nikakve operacije na njima. U našoj mreži ulaz je rečenica, odnosno riječi koje se pojavljuju u njoj.

2.2.2. Skriveni sloj


U ovom sloju modela prvo postavljamo ugradbeni sloj (eng. *embedding layer*) koji nam transformira ulazni jednodimenzionalni u dvodimenzionalni vektor. Njegova svrha je preoblikovati unešene rečenice u vektor ugrađivanja riječi tako da bi ih neuronska mreža mogla koristiti. Budući da je svaka rečenica različite duljine, a vektor mora biti fiksne duljine, potrebno je definirati maksimalan broj pojmova koje ćemo uzimati u obzir pri klasifikaciji.

Zatim ugrađujemo LSTM s mehanizmom pažnje. To je zapravo proširenje povratnih neuronskih mreža, gdje se povećava njihova memorija te se rješava problem učenja dugoročnih ovisnosti. Ugrađeni mehanizam riječima u modelu daje različitu pažnju

Razina pažnje daje nam predstavu o tome koje značajke mreža najviše gleda tijekom učenja i naknadnog klasificiranja, odnosno može reći u koji dio rečenice trebamo gledati.

Sljedeći primjer nam ilustrira kako mehanizam pozornosti može biti koristan kako za klasifikacijske zadatke tako i za zadaće označavanja redoslijeda.

i am feeling completely overwhelmed today



2.2.3. Izlazni sloj

Izlaz se realizira softmax funkcijom koja kao argument prima vektor, odnosno svaki element izlaza ovisi o cijelom skupu ulaznih elemenata.

2.2 Baza podataka

Općenito u literaturi nema mnogo baza podataka za prepoznavanje emocija koje se mogu pronaći.

Baza koju smo mi koristili sastoji se od 416 810 uzoraka neformalnih engleskih rečenica različitih duljina.

2.3 Analiza koda

Najprije obrađujemo podatke za analizu iz učitane odabrane baze *emotion.data* kako bi ih prilagodili modelu. Budući da su podaci u našoj bazi već tokenizirani (u našem slučaju tekst je rastavljen na rečenice), a veličina slova normalizirana, trebamo samo razdvojiti riječi.

Nakon prilagodbe stvaramo rječnik jedinstvenih pojmova pronađenih u bazi. Preciznije, inicijaliziramo dva rječnika *word2id* i *label2id*. U prvi rječnik dodajemo svaku riječ iz svake rečenice ukoliko se ona već ne nalazi u njemu, a nakon toga konstruiramo *label2id* koji nam služi za kodiranje riječi i oznaka.

Sada uvodimo Keras kojim ćemo tekst pretvoriti u numeričku reprezentaciju, odnosno kodirati uzorke iz baze s odgovarajućim cjelobrojnim vrijednostima. Svakoj riječi dodjeljujemo vektorsku reprezentaciju i to metodom inicijalizacije vektorskih reprezentacija.

Prvo formiramo odgovarajuće matrice X i Y . Obje matrice imaju 416 809 redaka budući da se odabrana baza sastoji od toliko rečenica, dok X sadrži 178 stupaca (*max_words*), a Y 6 stupaca (*len(label2id)*).

Zatim gradimo naš model, prikazan na sljedećoj slici, sloj po sloj.

Layer (type)	Output Shape	Param #	Connected to
input_1 (InputLayer)	(None, 178)	0	
embedding_1 (Embedding)	(None, 178, 100)	7530300	input_1[0][0]
dropout_1 (Dropout)	(None, 178, 100)	0	embedding_1[0][0]
bidirectional_1 (Bidirectional)	(None, 178, 200)	160800	dropout_1[0][0]
dropout_2 (Dropout)	(None, 178, 200)	0	bidirectional_1[0][0]
time_distributed_1 (TimeDistrib	(None, 178, 1)	201	dropout_2[0][0]
reshape_1 (Reshape)	(None, 178)	0	time_distributed_1[0][0]
attention_vec (Activation)	(None, 178)	0	reshape_1[0][0]
dot_1 (Dot)			attention_vec[0][0]
dense_2 (Dense)	(None, 100)	20100	dot_1[0][0]
dense_3 (Dense)	(None, 6)	606	dense_2[0][0]
Total params: 7,712,007			
Trainable params: 7,712,007			
Non-trainable params: 0			

Slika 3. Implementacija modela

Ulazni ugradbeni sloj svakoj riječi iz *word2id* riječnika već otprije kodiranoj brojevima od 0 do 75303, pridružuje 100-dimenzionalni kontekstni vektor. To realiziramo Keras funkcijom *keras.layers.Embedding* čiji je prvi argument veličina vokabulara ($\text{len}(\text{word2id}) + 1$) budući da se svaki ulazni integer koristi kao indeks za pristup tablici svih mogućih vektora. Drugi argument *embedding_dim* je veličina vektora pridruženog svakoj riječi koja je jednaka 100 kako smo prije istaknuli. Kao posljednji argument šaljemo duljinu ulazne rečenice koju smo fiksirali na duljinu najdulje rečenice u bazi *max_words*.

Sadržaj ove „tablice” koja povezuje indekse riječi sa ugradbenim vektorima prvo se inicijalizira na slučajan način, a kasnije te vrijednosti optimiziramo.

U ovom sloju još voditi računa o profinjenju modela, odnosno ne smijemo ga previše profinjiti. „Dropout” tehnikom ispuštanja nasumično odabranih neurona tijekom treniranja modela mreža postaje manje osjetljiva na specifične težine neurona. To rezultira mrežom koja je sposobna bolje generalizirati podatke odnosno smanjena je vjerojatnost da će se podaci „predobro istrenirati”. Ispuštanje provodimo funkcijom *keras.layers.Dropout(0.2)* kojom s danom vjerojatnošću od 20% ispuštamo neurone za svaki ciklus ažuriranja težine. U ovom sloju danu funkciju primjenjujemo na *embedded_inputs*.

3. PRIMJERI

Prvo ćemo pokazati kako program radi na samostalno izmišljenim rečenicama koje smatramo reprezentativnima.

```
no way i want to walk that dark street  
{ 'love': 0.0007970213, 'joy': 1.4339143, 'sadness': 3.0390804,  
'anger': 1.4296198, 'surprise': 0.001232966, 'fear': 94.09536 }
```

```
i think my husband is cheating on me  
{ 'love': 0.06337907, 'joy': 6.7076416, 'sadness': 23.845177, 'anger': 63.307182,  
'surprise': 0.0029246975, 'fear': 6.073693 }
```

Na kraju testiramo program na slučajno odabranim primjerima rečenica uvezene baze podataka.

```
i have to say sometimes i read some of these brilliant posts and feel somewhat intimidated about my own ad hoc patchy casual this is me struggling with my life at times blog
Percent of every of 6 emotions in sentence:
{'love': 0.00064496923, 'joy': 0.00084083347, 'sadness': 0.00012306002, 'anger': 2.270467e-05, 'surprise': 1.514742e-07, 'fear': 99.99837}
```

```
i do come up with a great autumnal outfit i feel so cute and cheery but it honestly takes more effort and energy to dress during these months than any others
Percent of every of 6 emotions in sentence:
{'love': 5.498292e-06, 'joy': 99.99375, 'sadness': 0.00043465133, 'anger': 0.0048710895, 'surprise': 2.6307117e-07, 'fear': 0.00093955896}
```

```
i splurged even though i m feeling very broke and ordered a sad light that can come with me to work
Percent of every of 6 emotions in sentence:
{'love': 6.0499384e-05, 'joy': 0.0017406468, 'sadness': 99.99762, 'anger': 0.00015394672, 'surprise': 2.0244976e-05, 'fear': 0.00040293808}
```

4. ZAKLJUČAK

Točnost ovakvog pristupa na potvrđenom problemu iznosi preko 90 posto. To je poprilično dobar rezultat obzirom na klasifikacijski zadatak koji sadrži 6 razreda.

Performanse se mogu poboljšati treniranjem modela uz još nekoliko ponavljanja.

5. LITERATURA

- [1] Chollet Francois, Deep learning in Phyton, 2018.
- [2] Basile P., Semeraro G., Polignano M., Gemmis M, A comparison of Word-Embeddings in Emotion Detection from Text using BiLSTM, CNN and Self-Attention, 2019.
- [3] <https://www.kaggle.com/>
- [4] <http://www.zemris.fer.hr/~ssegvic/du/>
- [5] <https://keras.io/datasets/>
- [6] <https://www.pluralsight.com/guides/classification-keras>
- [7] <https://www.microsoft.com/developerblog/2015/11/29/emotion-detection-and-recognition-from-text-using-deep-learning/>